

Caso 2 grupal

Predicción de Churn en un Operador de Telecomunicaciones Móviles

Sharid M. Rodríguez Wilches, Laura C. Ariza Ortiz, Juan D. Manosalva Duarte

Juan C. García Díaz

Estudiantes de Ciencia de Datos

Profesor, Departamento de Ingeniería Industrial

Pontificia Universidad Javeriana, Bogotá, Colombia

BUSINESS UNDERSTANDING

Business Objectives

El operador de telecomunicaciones del que trata este caso compite en un mercado donde ya prácticamente no hay clientes nuevos por conquistar. Entre cuatro y seis empresas se reparten la misma base de usuarios, así que la pelea ya no es por crecer sino por no perder lo que se tiene. Esto cambia completamente la lógica del negocio: ya no tiene sentido gastar en atraer clientes nuevos cuando retener uno cuesta cinco veces menos. El problema es que mensualmente cerca del 2% de los clientes se va, y aunque suene poco, en bases de cientos de miles de usuarios eso representa una cantidad enorme de ingresos que simplemente desaparece.

Para entender mejor el entorno donde opera este operador, usamos tres herramientas de análisis estratégico: PESTLE, Fuerzas de Porter y SWOT.

Análisis PESTLE

El PESTLE nos ayuda a ver qué está pasando afuera de la empresa y que, aunque no se puede controlar, sí afecta las decisiones que se toman:

Político	Económico	Social	Tecnológico	Legal	Ambiental
Regulación de telecomunicaciones por la CRC. Políticas de protección de datos personales (Ley 1581/2012). Apertura a inversión extranjera en el sector.	Mercado saturado con poca expansión. Alto costo de adquisición vs. retención (5x). Churn promedio	Digitalización acelerada del consumidor. Alta dependencia del celular. Creciente demanda de datos vs. voz. Segmento	Expansión de redes 5G. Analítica predictiva y CRM avanzado. Automatización en atención al cliente. IA para predicción de churn.	Normativa de protección al consumidor. Obligaciones de calidad de servicio (SLA). Regulación	Regulaciones de e-waste. Presión hacia infraestructura más eficiente en energía. Incentivos por facturación digital.

	del 2% mensual. Impacto de inflación en tarifas.	empresarial con necesidades distintas.		de portabilidad numérica.	
--	--	--	--	---------------------------	--

Análisis de las Fuerzas de Porter

El modelo de las cinco fuerzas de Porter permite evaluar la dinámica competitiva del sector de telecomunicaciones móviles:

Fuerza	Análisis
Rivalidad entre competidores	Alta — Mercado oligopólico con pocos actores (Claro, Movistar, Tigo, WOM). Competencia principalmente por precio y retención de clientes.
Amenaza de nuevos entrantes	Baja — Barreras de entrada altísimas: licencias de espectro, infraestructura, y capital inicial. El mercado está prácticamente copado.
Poder de negociación de proveedores	Media — Dependencia de fabricantes de equipos y proveedores de infraestructura de red, aunque hay opciones múltiples en el mercado global.
Poder de negociación de clientes	Alta — Los clientes postpago tienen acceso a portabilidad numérica y múltiples ofertas. El churn refleja directamente este poder.
Amenaza de productos sustitutos	Media-Alta — Apps de mensajería (WhatsApp, Telegram) y VoIP reducen el consumo de minutos/SMS. La demanda de datos sube, pero la voz cae.

En resumen, este es un sector donde la competencia es fuerte y los clientes tienen bastante poder. Por eso, saber anticipar quién se va a ir, y actuar antes de que pase, es una ventaja real.

Análisis SWOT

El SWOT (o DOFA) sintetiza los factores internos y externos más relevantes para el operador en el contexto del proyecto de analítica:

Fortalezas (Internas) Base de clientes postpago fidelizados con historial de consumo.	Debilidades (Internas) Tasa de churn del ~2% mensual que erosiona la base de clientes.
--	---

• Capacidad de recolección y almacenamiento de datos detallados por cliente. • Infraestructura operativa consolidada y equipo técnico disponible. • Acceso a herramientas de analítica para CRM avanzado.	• Estrategias de retención reactivas (sin modelo predictivo robusto). • Costos elevados de retención sin segmentación clara por valor de cliente.
Oportunidades (Externas) • Uso de modelos predictivos de churn para anticipar deserción. • Segmentación de clientes según CLTV para optimizar inversión en retención. • Tendencia de digitalización que facilita comunicación personalizada. • Mercado con portabilidad: retener bien es diferenciador competitivo.	Amenazas (Externas) • Portabilidad numérica facilita que clientes migren a competidores. • Presión de precios por intensa rivalidad en mercado saturado. • Sustitutos digitales (WhatsApp, VoIP) reducen consumo de voz. • Regulaciones más estrictas sobre uso de datos personales de clientes.

Lo que nos dice el SWOT es que el operador ya tiene los datos y la infraestructura para hacer esto bien. El reto es convertir esa capacidad en acciones concretas que realmente retengan clientes sin gastar de más.

Business Goal

A partir del análisis anterior, se definen los siguientes objetivos de negocio:

- BG1: Reducir la tasa de churn mensual de clientes pospago identificando anticipadamente a los clientes con mayor probabilidad de deserción.
- BG2: Optimizar el gasto en retención priorizando las intervenciones hacia los clientes con mayor valor de largo plazo (CLTV), evitando ofrecer incentivos a quienes no los necesitan.

Business Success Criteria

Los criterios de éxito que permiten evaluar el cumplimiento de los objetivos de negocio son:

- KPI-BG1: Reducir la tasa de churn mensual en al menos un 20% durante los primeros seis meses de implementación. Para entender por qué ese 20%: si la tasa base es ~2% mensual y se logra bajarla a 1.6%, en una base de 100,000 clientes eso significa 400 personas menos que se van cada mes. A un ingreso promedio de \$50,000 COP por usuario, son \$20,000,000 COP mensuales preservados, lo que alcanza para cubrir la inversión en el modelo y en los incentivos de retención. En el contexto de este proyecto, ese impacto se estima a partir de la simulación sobre la base de prueba, no de una implementación real.

- KPI-BG2: Reducir el costo promedio por cliente retenido en al menos un 15%, evitando intervenciones innecesarias sobre clientes que no iban a desertar de todas formas. Hoy, sin un modelo, se tiende a intervenir sobre toda la base o de forma reactiva, lo que implica gastar en falsos positivos. El 15% es una meta interna conservadora que se sustenta en la simulación de costos del KPI-DMG2: si el modelo filtra bien los falsos positivos, el ahorro proporcional supera ese umbral con los supuestos definidos.

Dado que el dataset no tiene una variable de CLTV directa, lo vamos a aproximar con un proxy: *Facturación acumulada semestral* $\times$ (*Antigüedad en meses* / 6). Esto da una estimación del ingreso histórico anualizado por cliente y nos permite dividir la base en terciles para priorizar los de mayor valor.

Data Mining Goal

Para responder a los objetivos de negocio planteados, se definen los siguientes objetivos analíticos:

- DMG1: Construir un modelo de clasificación binaria que prediga si un cliente pospago entrará en churn, maximizando el área bajo la curva ROC (AUC-ROC) sobre la base de prueba de Kaggle.
- DMG2: Encontrar el punto de corte óptimo del modelo que maximice las ganancias de la estrategia de retención, teniendo en cuenta los costos de intervención y el valor esperado de retener a cada cliente.

Data Mining Success Criteria

Los criterios de éxito técnicos asociados a cada objetivo analítico son:

- KPI-DMG1: Lograr un $AUC-ROC \geq 0.80$ en la base de prueba. Usamos 0.80 como piso porque, según la escala de Hosmer-Lemeshow (2000), valores entre 0.80 y 0.90 se consideran de discriminación excelente, mientras que entre 0.70 y 0.80 son apenas aceptables. Queremos que el modelo tenga capacidad predictiva real, no que apenas supere el azar.
- KPI-DMG2: Identificar un punto de corte donde la ganancia esperada sea positiva. Para calcularlo, usamos estos supuestos: costo de intervención por cliente = \$15,000 COP; ingreso mensual preservado = facturación semestral / 6; tasa de éxito de retención = 30% (de cada cliente intervenido, se retiene uno de cada tres). La fórmula es: $(P(\text{churn}|\text{cliente}) \times 0.30 \times \text{ARPU mensual}) - \$15,000$, y el punto de corte óptimo es el que maximiza esa ganancia sumada sobre toda la base de prueba.

DATA UNDERSTANDING

Describe data

El proyecto utilizó dos bases de datos en formato Excel: traintelco.xlsx (base de entrenamiento) y testelco.xlsx (base de prueba), proporcionadas directamente por la competencia de Kaggle. Ambas bases comparten el mismo conjunto de variables de entrada; la diferencia radica en que traintelco incluye la variable objetivo resultado (indicador binario de churn: 1 = desertó, 0 = permaneció), mientras que testelco no la contiene, pues corresponde a los registros sobre los cuales se generan las predicciones para la competencia.

Las variables disponibles en ambas bases son: id (identificador del cliente, numérico), Fecha de nacimiento (fecha, usada para calcular la edad), Fecha inicio contrato (fecha de vinculación, usada para calcular antigüedad), tipo cliente (categórica), Factura online (categórica binaria), Plan de datos (categórica), facturación (numérica continua, valor facturado acumulado), minutos (numérica entera, minutos de voz consumidos), mora (numérica, valor en mora acumulado) y Antigüedad Equipo (numérica, días desde la adquisición del dispositivo). En total, la base de entrenamiento cuenta con 9 variables originales más el identificador y la variable objetivo.

Explore data

El análisis exploratorio se realizó sobre la base de entrenamiento completa. En cuanto a las variables numéricas, facturación y mora presentan distribuciones con cola derecha pronunciada, lo que motivó el uso de transformaciones logarítmicas en la etapa de preparación. Minutos también muestra concentración en valores bajos con algunos valores extremos altos. Las variables categóricas (tipo cliente, Factura online y Plan de datos) fueron inspeccionadas con tablas de frecuencia para verificar la distribución de categorías y detectar posibles desbalances. La variable objetivo resultado presenta desbalance de clases coherente con la tasa de churn esperada (~2% mensual), lo cual fue considerado en el diseño de la validación cruzada estratificada. El análisis se realizó sobre la base de entrenamiento completa antes de cualquier transformación.

Verify Data Quality

Se verificó la calidad de los datos mediante la inspección de valores faltantes con `colSums(is.na(train))`, tanto antes como después de la ingeniería de variables. No se identificaron valores faltantes en las variables originales. Las variables derivadas tampoco generaron NA, dado que las fórmulas de cálculo incluyen denominadores con sumandos de protección (+1) para evitar divisiones por cero. No se detectaron valores imposibles explícitos, aunque las distribuciones de variables como mora y facturación presentan valores atípicos altos que fueron tratados mediante transformaciones logarítmicas en la etapa de preparación.

DATA PREPARATION

Clean data

No se realizó ningún proceso de limpieza de datos en sentido estricto, dado que la inspección de valores faltantes (verify data quality) no detectó NAs en ninguna variable original. Las tres

variables categóricas (tipo cliente, Factura online y Plan de datos) fueron convertidas explícitamente a tipo factor en R mediante `as.factor()`, paso necesario para su correcto tratamiento en la etapa de one-hot encoding. Las columnas id, Fecha de nacimiento y Fecha inicio contrato fueron eliminadas del conjunto de predictores por ser fuentes potenciales de fuga de información o por haber sido ya codificadas en variables derivadas.

Construct data

Se construyó un conjunto ampliado de variables mediante una función de ingeniería de variables (`feature_engineering`) aplicada de forma idéntica a train y test, tomando como fecha de corte el 1 de enero de 2019. Las variables derivadas se agrupan en dos familias: (1) variables de normalización temporal, como edad (años desde la fecha de nacimiento), antigüedad_cliente (días desde el inicio del contrato), facturacion_mes, minutos_mes y ratios como facturacion_por_minuto, mora_antigüedad, mora_facturacion y equipo_cliente_ratio; y (2) transformaciones logarítmicas para suavizar distribuciones con cola derecha (`log_facturacion`, `log_minutos`, `log_mora`). Adicionalmente, se incorporaron términos de interacción y polinomios para capturar relaciones no lineales: `edad_x_facturacion`, `edad_x_minutos`, `facturacion_x_minutos`, `edad2`, `minutos2` y `facturacion2`. Finalmente, las variables categóricas fueron transformadas mediante one-hot encoding usando `dummyVars()` del paquete `caret`, garantizando que el mismo esquema de codificación se aplicara tanto a train como a test.

Dataset description

El dataset final en formato tidy dataset contiene una fila por cliente y una columna por variable, sin valores faltantes. Luego de aplicar la ingeniería de variables y el one-hot encoding, la matriz de predictores incluye las variables originales numéricas, las 20 variables derivadas y las columnas generadas por la codificación de las categóricas. La variable objetivo resultado se mantiene separada como vector numérico binario (0/1) para su uso directo en XGBoost. El dataset de test presenta la misma estructura de predictores pero sin la variable objetivo, pues corresponde al conjunto sobre el que se generan las predicciones finales para la competencia.

MODELING & EVALUATION

Select Modeling Techniques

Para el modelado se utilizó un ensamble de dos modelos XGBoost (Extreme Gradient Boosting), una técnica de aprendizaje supervisado basada en árboles de decisión potenciados mediante gradient boosting. La variable objetivo correspondía a un problema de clasificación binaria (churn/no churn), y la métrica de evaluación utilizada fue el área bajo la curva ROC (AUC), de acuerdo con las reglas de la competencia.

Los modelos utilizados fueron:

XGBoost A

- `eta = 0.01`
- `max_depth = 4`
- `subsample = 0.8`

- $\text{colsample_bytree} = 0.8$
- $\text{min_child_weight} = 5$
- $\text{gamma} = 0.5$

XGBoost B

- $\text{eta} = 0.03$
- $\text{max_depth} = 3$
- $\text{subsample} = 0.9$
- $\text{colsample_bytree} = 0.9$
- $\text{min_child_weight} = 8$
- $\text{gamma} = 1$

Las predicciones finales se obtuvieron mediante un ensamble ponderado:

$$\text{Predicción}_{\text{final}} = 0.7 \times \text{XGBoost}_A + 0.3 \times \text{XGBoost}_B$$

Esta estrategia permitió combinar modelos con configuraciones diferentes, reduciendo la varianza y mejorando la capacidad de generalización sobre datos no observados.

A diferencia de modelos estadísticos tradicionales como la regresión lineal o la regresión logística, XGBoost no requiere el cumplimiento estricto de supuestos como:

- Normalidad de las variables explicativas.
- Normalidad de los residuos.
- Homocedasticidad.
- Relaciones lineales entre predictores y variable respuesta.
- Independencia entre variables predictoras.
- Ausencia de multicolinealidad.

Por esta razón, XGBoost resulta especialmente adecuado para bases de datos empresariales donde pueden existir relaciones no lineales, interacciones complejas entre variables y distribuciones alejadas de la normalidad.

No obstante, sí existen algunas consideraciones prácticas para su aplicación:

- Disponer de una cantidad suficiente de observaciones para entrenar árboles con capacidad predictiva adecuada.
- Mantener una proporción razonable de casos positivos y negativos para que el modelo pueda aprender patrones representativos de ambas clases.
- Realizar validación cruzada para evaluar la estabilidad del modelo y controlar el sobreajuste.
- Ajustar adecuadamente los hiperparámetros relacionados con la complejidad de los árboles y el proceso de boosting.
- Utilizar mecanismos de regularización y early stopping para mejorar la capacidad de generalización.
- Emplear una métrica alineada con el objetivo del problema, en este caso el AUC ROC.

Estas condiciones fueron consideradas durante el desarrollo del proyecto mediante validación cruzada estratificada de 5 particiones, ajuste iterativo de hiperparámetros, regularización incorporada en XGBoost y la construcción de un ensamble de modelos con configuraciones complementarias. La combinación ponderada de ambos modelos permitió aprovechar fortalezas distintas de cada configuración y obtener un mejor desempeño sobre datos no observados.

Generate Test Design

Se diseñó un esquema experimental basado en la comparación sistemática de distintas estrategias de ingeniería de variables y configuraciones del algoritmo XGBoost. Dado que la competencia evaluaba el desempeño mediante el área bajo la curva ROC (AUC), esta métrica se utilizó como criterio principal para comparar los modelos.

La evaluación se realizó mediante validación cruzada estratificada de 5 particiones, preservando la proporción de clientes con y sin churn en cada subconjunto. Este procedimiento permitió obtener una estimación robusta de la capacidad de generalización de los modelos y reducir la dependencia de una única partición entrenamiento-validación.

El diseño experimental se desarrolló en tres etapas:

1. Comparación de estrategias de ingeniería de variables

Inicialmente se construyó un conjunto de variables derivadas a partir de las variables originales, incluyendo:

- Edad del cliente.
- Antigüedad del cliente.
- Facturación mensual promedio.
- Minutos promedio por mes.
- Facturación por minuto.
- Mora relativa a la antigüedad.
- Facturación relativa a la antigüedad.
- Transformaciones logarítmicas de facturación, minutos y mora.
- Indicadores relativos como mora/facturación, mora/minutos y antigüedad del equipo relativa a la antigüedad del cliente.

Con este conjunto de variables se entrenó un modelo base de XGBoost, obteniendo un AUC promedio de validación cruzada cercano a 0.8765.

Posteriormente se evaluó una segunda estrategia de ingeniería de variables basada en interacciones y términos polinómicos:

- $\text{edad} \times \text{facturación}$
- $\text{edad} \times \text{minutos}$
- $\text{facturación} \times \text{minutos}$
- $\text{facturación} \times \text{antigüedad del cliente}$
- edad^2

- minutos²
- facturación²

Estas variables buscaban capturar relaciones no lineales e interacciones entre predictores. La comparación se realizó manteniendo la misma metodología de validación para aislar el efecto de la ingeniería de variables sobre el desempeño predictivo.

2. Comparación de configuraciones de XGBoost

Una vez identificada la estrategia de variables más prometedora, se evaluaron múltiples configuraciones de hiperparámetros de XGBoost, variando principalmente:

- Tasa de aprendizaje (eta).
- Profundidad máxima de los árboles (max_depth).
- Proporción de observaciones utilizadas por árbol (subsample).
- Proporción de variables utilizadas por árbol (colsample_bytree).
- Restricciones de complejidad mediante min_child_weight y gamma.

Las dos configuraciones con mejor desempeño fueron:

Modelo A

- eta = 0.01
- max_depth = 4
- subsample = 0.8
- colsample_bytree = 0.8
- min_child_weight = 5
- gamma = 0.5

Modelo B

- eta = 0.03
- max_depth = 3
- subsample = 0.9
- colsample_bytree = 0.9
- min_child_weight = 8
- gamma = 1

3. Evaluación de ensambles

Finalmente se evaluó un ensemble ponderado de ambos modelos:

$$Predicción_{final} = 0.7 \times ModeloA + 0.3 \times ModeloB$$

El objetivo fue combinar modelos con sesgos y varianzas diferentes para mejorar la capacidad de generalización. Aunque las diferencias observadas en validación cruzada fueron pequeñas, el ensemble obtuvo el mejor desempeño sobre los datos ocultos de la competencia, razón por la cual fue seleccionado como solución final.

Control del sobreajuste y subajuste

Para controlar el sobreajuste se utilizaron:

- Validación cruzada estratificada de 5 particiones.
- Early stopping durante el entrenamiento.
- Muestreo aleatorio de observaciones mediante el parámetro subsample.
- Muestreo aleatorio de variables mediante colsample_bytree.
- Restricciones de complejidad a través de gamma y min_child_weight.

Para descartar problemas de subajuste se experimentó con configuraciones de árboles más profundos, diferentes tasas de aprendizaje y niveles alternativos de regularización. Dado que estas modificaciones no produjeron mejoras consistentes en validación, se concluyó que los modelos seleccionados aprovechaban adecuadamente la información disponible sin presentar evidencia de subajuste severo.

Selección de variables

No se implementó un procedimiento formal de selección de variables como Forward Selection, Backward Selection o LASSO. Esta decisión se fundamentó en que el conjunto de datos contenía un número reducido de variables originales y en que XGBoost incorpora mecanismos internos de selección de variables mediante la optimización de las divisiones de los árboles.

La permanencia o eliminación de variables derivadas se evaluó principalmente a través de su impacto en el AUC obtenido durante la validación cruzada y en el desempeño final observado en la competencia.

Build Model

El modelado se realizó utilizando XGBoost (Extreme Gradient Boosting), debido a su capacidad para modelar relaciones no lineales, capturar interacciones entre variables y controlar el sobreajuste mediante mecanismos de regularización incorporados.

Como punto de partida se construyó un modelo base utilizando las variables derivadas obtenidas durante la fase de preparación de datos. La configuración inicial utilizada fue:

- eta = 0.01
- max_depth = 4
- subsample = 0.8
- colsample_bytree = 0.8
- min_child_weight = 5
- gamma = 0.5
- nrounds = 4000
- early_stopping_rounds = 200

La evaluación se realizó mediante validación cruzada estratificada de 5 particiones utilizando AUC ROC como criterio principal de desempeño. Esta configuración obtuvo un AUC promedio cercano a 0.8765 en validación cruzada y un desempeño aproximado de 0.8843 en la evaluación de Kaggle.

Posteriormente se realizaron experimentos adicionales modificando la complejidad de los árboles, la tasa de aprendizaje y los mecanismos de regularización. A partir de estas pruebas se identificaron dos configuraciones que mostraban comportamientos complementarios y buen desempeño predictivo.

XGBoost A

- $\eta = 0.01$
- $\text{max_depth} = 4$
- $\text{subsample} = 0.8$
- $\text{colsample_bytree} = 0.8$
- $\text{min_child_weight} = 5$
- $\gamma = 0.5$
- $\text{nrounds} = 4000$
- $\text{early_stopping_rounds} = 200$

XGBoost B

- $\eta = 0.03$
- $\text{max_depth} = 3$
- $\text{subsample} = 0.9$
- $\text{colsample_bytree} = 0.9$
- $\text{min_child_weight} = 8$
- $\gamma = 1$
- $\text{nrounds} = 4000$
- $\text{early_stopping_rounds} = 200$

Adicionalmente se evaluó un ensamble de tres modelos XGBoost utilizando diferentes configuraciones de hiperparámetros y una combinación ponderada de las predicciones:

$$\text{Predicción}_{\text{final}} = 0.5 \times \text{Modelo}_A + 0.3 \times \text{Modelo}_B + 0.2 \times \text{Modelo}_C$$

donde el tercer modelo utilizaba:

- $\eta = 0.01$
- $\text{max_depth} = 5$
- $\text{subsample} = 0.75$
- $\text{colsample_bytree} = 0.75$
- $\text{min_child_weight} = 3$
- $\gamma = 0.3$

Aunque este ensamble presentó un desempeño competitivo, no logró superar consistentemente los resultados obtenidos por la combinación de dos modelos.

La mejor solución encontrada correspondió a un ensamble de los modelos XGBoost A y XGBoost B, utilizando una combinación ponderada de probabilidades:

$$\text{Predicción}_{\text{final}} = 0.7 \times \text{XGBoost}_A + 0.3 \times \text{XGBoost}_B$$

La selección de esta configuración se realizó a partir de los resultados obtenidos tanto en validación cruzada como en la evaluación de Kaggle. El ensamble logró aprovechar las fortalezas de ambas configuraciones, generando predicciones más robustas y mejorando la

capacidad de generalización frente a los modelos individuales. Esta estrategia obtuvo el mejor desempeño global del proyecto y fue la solución utilizada para la entrega final de la competencia.

Assess Model

La evaluación de los modelos se realizó utilizando el área bajo la curva ROC (AUC), métrica oficial de la competencia y una medida apropiada para problemas de clasificación binaria. Esta métrica permite evaluar la capacidad del modelo para diferenciar entre clientes que abandonan el servicio y clientes que permanecen activos.

Comparación de modelos

Durante el proceso de modelado se evaluaron múltiples alternativas combinando distintas estrategias de ingeniería de variables, configuraciones de hiperparámetros y ensambles de modelos.

El modelo base de XGBoost, construido a partir de variables derivadas relacionadas con edad, antigüedad, facturación, consumo y transformaciones logarítmicas, obtuvo un AUC promedio de validación cruzada cercano a 0.8765 y un desempeño aproximado de 0.8843 en la evaluación de Kaggle.

Posteriormente se incorporaron variables de interacción y términos polinómicos, permitiendo capturar relaciones más complejas entre los predictores. Estas variables incluyeron interacciones entre edad, facturación, minutos consumidos y antigüedad del cliente, así como términos cuadráticos para algunas variables numéricas.

Finalmente se evaluaron diferentes configuraciones de XGBoost y estrategias de ensamble. La mejor solución correspondió a un ensamble ponderado de dos modelos XGBoost, el cual obtuvo un desempeño superior al de los modelos individuales y alcanzó un AUC de aproximadamente 0.8881 en la competencia.

Desempeño, robustez y calidad del modelo

Los resultados obtenidos muestran una alta consistencia entre las métricas de validación cruzada y los resultados observados sobre los datos ocultos de la competencia. Esta estabilidad sugiere que el modelo posee una adecuada capacidad de generalización y no presenta evidencia significativa de sobreajuste.

La robustez del modelo también se vio favorecida por el uso de validación cruzada estratificada de cinco particiones, early stopping, regularización mediante hiperparámetros y estrategias de subsampling. Estos mecanismos permitieron controlar la complejidad del modelo y obtener predicciones estables sobre diferentes subconjuntos de datos.

La comparación entre modelos individuales y ensambles mostró que la combinación de modelos con configuraciones complementarias permitía reducir la varianza de las predicciones y mejorar el desempeño general sobre datos no observados.

Selección del modelo final

La solución finalmente seleccionada correspondió a un ensamble de dos modelos XGBoost, utilizando una combinación ponderada de las probabilidades predichas:

$$Predicción_{final} = 0.7 \times XGBoost_A + 0.3 \times XGBoost_B$$

Esta alternativa fue seleccionada debido a que obtuvo el mejor desempeño global durante la competencia, superando tanto a los modelos individuales como a otras estrategias de ensamble evaluadas. Además, logró el mejor resultado entre todos los equipos participantes, obteniendo el primer lugar en la clasificación final de la competencia.

Cumplimiento de los objetivos de minería de datos

El objetivo de minería de datos consistía en construir un modelo capaz de identificar clientes con alta probabilidad de churn para apoyar acciones preventivas de retención. Los resultados obtenidos demuestran que el modelo posee una alta capacidad discriminativa, permitiendo priorizar de manera efectiva los clientes con mayor riesgo de abandono.

El valor de AUC alcanzado indica que el modelo es capaz de ordenar correctamente a los clientes según su riesgo relativo de desertar, proporcionando una herramienta útil para la toma de decisiones comerciales y operativas.

Impacto esperado sobre los KPI de negocio

Aunque el modelo no fue implementado en un entorno productivo real, los resultados permiten estimar su impacto potencial sobre los indicadores definidos en la fase de entendimiento del negocio.

KPI-BG1: Reducir la tasa de churn mensual en al menos un 20%

El modelo permite identificar de forma anticipada a los clientes con mayor probabilidad de abandono, facilitando la focalización de campañas de retención. Bajo el supuesto planteado inicialmente, una reducción de la tasa de churn mensual de 2% a 1.6% implicaría evitar aproximadamente 400 bajas mensuales por cada 100.000 clientes. Considerando un ingreso promedio de \$50.000 COP por cliente, esto representaría cerca de \$20 millones de pesos mensuales preservados. El alto nivel de discriminación alcanzado por el modelo respalda la viabilidad de este objetivo, aunque su cumplimiento definitivo solo podría verificarse mediante una implementación operativa y un seguimiento posterior.

KPI-BG2: Reducir el costo promedio por cliente retenido en al menos un 15%

La capacidad del modelo para concentrar los esfuerzos de retención sobre clientes con mayor riesgo permite disminuir intervenciones innecesarias sobre clientes que probablemente permanecerían activos sin incentivos adicionales. Esto contribuye a reducir costos asociados a descuentos, promociones y campañas masivas, mejorando la eficiencia de las acciones de retención. Dado el desempeño alcanzado por el modelo, se espera que el filtrado de clientes de

alto riesgo contribuya al cumplimiento de la meta de reducción de costos establecida inicialmente.

En conjunto, los resultados obtenidos evidencian que el modelo final cumple satisfactoriamente los objetivos de minería de datos y constituye una herramienta con potencial para generar beneficios económicos y operativos relevantes para la organización.

DEPLOYMENT

El modelo desarrollado permite identificar clientes con alta probabilidad de churn antes de que abandonen el operador. Sin embargo, el valor real para el negocio no está en la predicción en sí misma, sino en la capacidad de convertir dicha información en acciones concretas de retención. Por esta razón, se proponen las siguientes estrategias de implementación alineadas con los objetivos de negocio definidos.

Estrategia 1: Campañas de retención focalizadas para clientes de alto riesgo

Objetivo asociado: BG1 – Reducir la tasa de churn mensual.

Utilizando el score de riesgo generado por el modelo, los clientes pueden clasificarse en niveles de riesgo (alto, medio y bajo). Los esfuerzos comerciales deben concentrarse inicialmente en el grupo de mayor riesgo, priorizando aquellos clientes con mayor probabilidad de abandono.

Programs (Kotler)

- Ofertas personalizadas de permanencia.
- Bonificaciones temporales de datos.
- Descuentos en renovación de equipos.
- Beneficios exclusivos para clientes con riesgo alto.

Costos y beneficios esperados

Actualmente, sin un modelo predictivo, las campañas de retención suelen aplicarse de manera masiva o reactiva. El modelo permite concentrar las intervenciones únicamente sobre los clientes con mayor probabilidad de churn.

Bajo los supuestos definidos en el proyecto, una reducción de la tasa de churn mensual de 2% a 1.6% permitiría evitar aproximadamente 400 bajas mensuales por cada 100.000 clientes. Considerando un ingreso promedio de \$50.000 COP por cliente, esto representa aproximadamente \$20 millones de pesos mensuales preservados.

Estrategia 2: Priorización de clientes según valor económico (CLTV)

Objetivo asociado: BG2 – Optimizar el gasto en retención.

No todos los clientes tienen el mismo valor para la compañía. Por esta razón, se propone combinar la probabilidad de churn generada por el modelo con el proxy de CLTV definido durante el proyecto:

$$CLTV \approx \text{Facturación acumulada semestral} \times (\text{Antigüedad en meses} / 6)$$

Los clientes se clasificarán en terciles de valor (alto, medio y bajo), permitiendo asignar incentivos proporcionales al valor económico esperado.

Programs (Kotler)

- Incentivos premium para clientes de alto valor.
- Ofertas estándar para clientes de valor medio.
- Estrategias automatizadas de bajo costo para clientes de menor valor.

Costos y beneficios esperados

Esta estrategia evita gastar recursos de retención sobre clientes con bajo riesgo de churn o bajo valor económico. Al focalizar las intervenciones, se espera cumplir la meta de reducir en al menos 15% el costo promedio por cliente retenido establecida en los KPI de negocio.

Estrategia 3: Sistema de monitoreo y CRM predictivo

Objetivos asociados: BG1 y BG2.

Se recomienda integrar el modelo dentro del CRM corporativo para ejecutar evaluaciones periódicas sobre toda la base de clientes. Cada cliente recibiría un score actualizado de riesgo de abandono y una clasificación de prioridad comercial.

Programs (Kotler)

- Actualización periódica de scores de churn.
- Automatización de alertas para equipos comerciales.
- Activación automática de campañas según nivel de riesgo.
- Tableros de seguimiento para equipos de marketing y retención.

Costos y beneficios esperados

La automatización reduce los tiempos de reacción ante señales de abandono y permite escalar las acciones de retención sin incrementar proporcionalmente los costos operativos. Además, facilita la medición continua del desempeño de las campañas y la mejora progresiva de las estrategias de fidelización.

Potenciales siguientes pasos de análisis

Aunque el modelo alcanzó el mejor desempeño de la competencia, existen oportunidades de mejora para futuras iteraciones:

1. Incorporar variables adicionales relacionadas con servicio al cliente, reclamos, calidad de red y uso de datos móviles.
2. Implementar experimentos A/B para medir el efecto real de las campañas de retención sobre la reducción del churn.
3. Construir modelos de uplift que permitan identificar qué clientes realmente responden a una intervención comercial.
4. Estimar un CLTV más preciso utilizando información histórica completa de ingresos y permanencia.

5. Monitorear periódicamente el desempeño del modelo para detectar cambios en el comportamiento de los clientes y reentrenarlo cuando sea necesario.

En conclusión, el modelo desarrollado demuestra una alta capacidad para identificar clientes con riesgo de abandono y constituye una herramienta de apoyo para la toma de decisiones comerciales. Su implementación permitiría orientar los recursos de retención hacia los clientes con mayor probabilidad de churn y mayor valor económico, contribuyendo al cumplimiento de los objetivos estratégicos de reducción de churn y optimización de costos.